Lista01-Pedro-Alves

November 2, 2026

1 Lista de Exercícios 1 - Econometria Avançada (2026)

Grupo: Pedro Alves de Souza Neto

[1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from scipy.stats import norm, poisson, chi2, t

plt.rcParams.update({"figure.figsize": (9, 4.5), "axes.grid": True, "grid.
 ↪alpha": 0.3})
```

[2]:
```
y = np.array([21,28,33,38,35,39,27,24,24,26,22,38,␣
 ↪23,26,30,36,22,21,16,28,23,20,22,39,
              16,21,27,31,25,31,31,16,20,24,22,32,␣
 ↪26,23,22,40,23,29,32,24,28,24,25,51,
              32,19,19,16,26,22,24,35,29,34,14,27,␣
 ↪19,19,38,17,40,13,21,26,32,16,24,27,
              33,23,19,18,25,28,30,28,34,31,27,17,␣
 ↪29,19,38,32,40,38,30,35,40,46,32,37,
              27,19,40,25,26,28,42,31,34,38,39,54,␣
 ↪38,28,43,42,38,50,44,38,41,44,28,56,
              31,33,39,31,49,39,46,46,50,36,25,54, 31,34,41,40,43,50,48,47])
n = len(y)
dates = pd.date_range("2015-01", periods=n, freq="MS")
ys = pd.Series(y, index=dates, name="mortes")

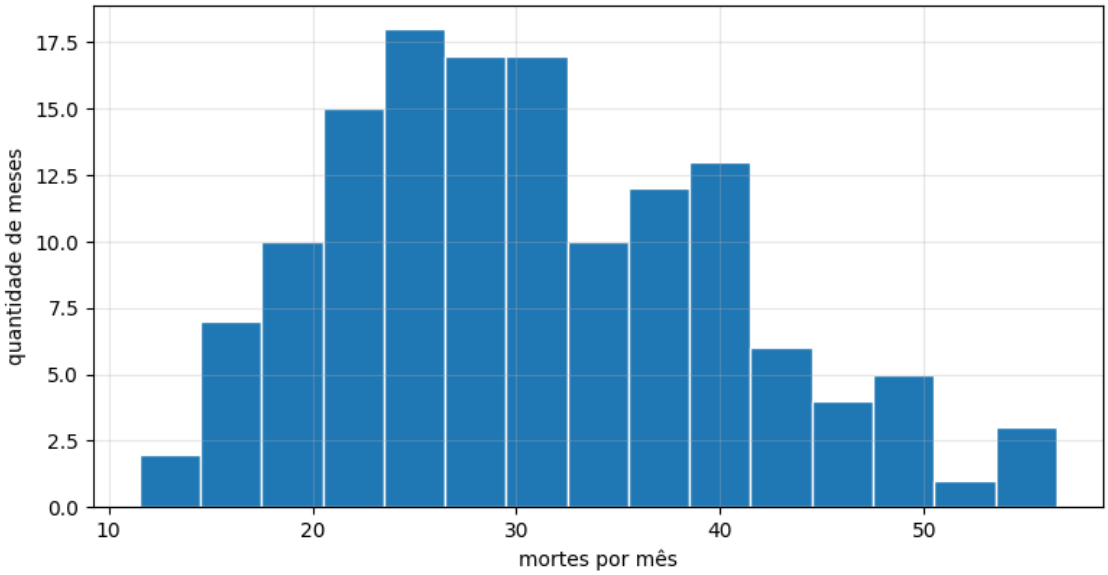
assert n == 140 and y[0] == 21 and y[-1] == 47
```

1.1 Questão 1: Histograma

[3]:
```
bins = np.arange(11.5, 59.5, 3)  # intervalos de largura 3 centrados em inteiros
fig, ax = plt.subplots()
ax.hist(y, bins=bins, edgecolor="white")
ax.set_xlabel("mortes por mês")
ax.set_ylabel("quantidade de meses")
```

```
plt.show()

print(pd.Series({"média": y.mean(), "mediana": np.median(y), "variância␣
 ↪(ddof=1)": y.var(ddof=1),
                  "desvio padrão (ddof=1)": y.std(ddof=1), "mínimo": y.min(),␣
 ↪"máximo": y.max()}).round(2).to_string())
fmt = lambda s: s.rename(lambda d: d.strftime("%Y-%m")).to_dict()
print("meses com mais mortes:", fmt(ys.nlargest(4)))
print("meses com menos mortes: ", fmt(ys.nsmallest(2)))
```




```
média                     30.91
mediana                   30.00
variância (ddof=1)        92.25
desvio padrão (ddof=1)     9.60
mínimo                    13.00
máximo                    56.00
meses com mais mortes: {'2024-12': 56, '2023-12': 54, '2025-12': 54, '2018-12':
51}
meses com menos mortes:  {'2020-06': 13, '2019-11': 14}
```

1.1.1 Resposta 1

Média = 30,91, mediana = 30, variância = 92,25, desvio padrão = 9,60; variando de 13 a 56. O histograma é levemente deslocado para a esquerda; os meses mais críticos são todos dezembros. A variância é três vezes maior que a média.

1.2 Questão 2: Modelo Gaussiano:

1.2.1 Resposta 2(a)

$$\ell(\mu, \sigma^2) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{t=1}^{n}(y_t - \mu)^2$$

Zerando as derivadas, a gente chega em $\hat{\mu} = \bar{y}$ e $\hat{\sigma}^2 = \frac{1}{n}\sum_{t=1}^{n}(y_t - \bar{y})^2$.

[4]:
```
mu_hat = y.mean()
sigma2_hat = y.var(ddof=0)    # EMV divide por n
s = y.std(ddof=1)             # s^2 não viesado divide por n-1; usado no␣
 ↪intervalo t
t_q = t.ppf(0.975, n - 1)
ci_mu = (mu_hat - t_q * s / np.sqrt(n), mu_hat + t_q * s / np.sqrt(n))

pd.Series({"mu_hat": mu_hat, "sigma2_hat (EMV, /n)": sigma2_hat, "s^2 (/(n-1))":
 ↪ s**2,
           "IC 95% inferior": ci_mu[0], "IC 95% superior": ci_mu[1]}).round(3).
 ↪to_frame("Modelo Gaussiano")
```

[4]:

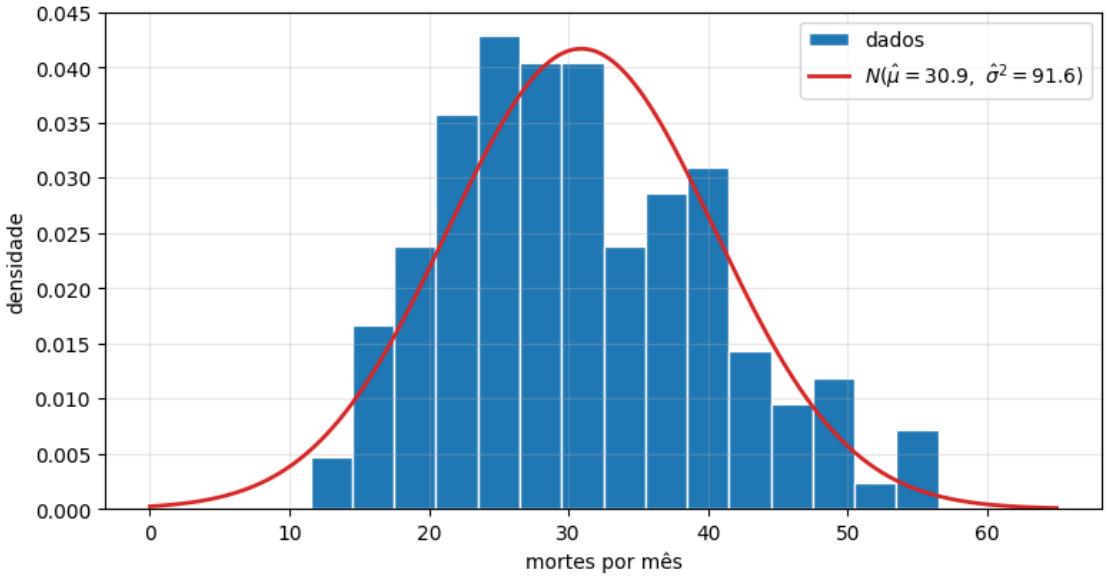
	Modelo Gaussiano
mu_hat	30.914
sigma2_hat (EMV, /n)	91.593
s^2 (/(n-1))	92.252
IC 95% inferior	29.309
IC 95% superior	32.519

1.2.2 Resposta 2(b)

$\hat{\mu} = 30{,}91$, $\hat{\sigma}^2 = 91{,}59$; IC de 95% para μ: $\bar{y} \pm t_{0.975,139}\, s/\sqrt{n} = [29{,}31,\ 32{,}52]$.

[5]:
```
grid = np.linspace(0, 65, 400)
fig, ax = plt.subplots()
ax.hist(y, bins=bins, density=True, edgecolor="white", label="dados")
ax.plot(grid, norm.pdf(grid, mu_hat, np.sqrt(sigma2_hat)), lw=2, color="C3",
        label=rf"$N(\hat\mu={mu_hat:.1f},\ \hat\sigma^2={sigma2_hat:.1f})$")
ax.set_xlabel("mortes por mês")
ax.set_ylabel("densidade")
ax.legend()
plt.show()

print(f"P(Y < 0) na normal ajustada = {norm.cdf(0, mu_hat, np.sqrt(sigma2_hat)):
 ↪.1e}")
```




```
P(Y < 0) na normal ajustada = 6.2e-04
```

1.2.3 Resposta 2(c)

Deixa à desejar, acerta o centro e a dispersão geral, mas erra o formato (os dados reais são assimétricos). A Gaussiana não trabalha com contagens inteiras e não negativas, que a variância cresce junto com a média e também ignora a dinâmica temporal(sazional).

1.3 Questão 3: Modelo de Poisson:

1.3.1 Resposta 3(a)

$$\ell(\lambda) = \left(\sum_t y_t\right) \log \lambda - n\lambda + \text{constante}, \qquad \ell'(\lambda) = 0 \Rightarrow \hat{\lambda} = \bar{y}.$$

$I(\lambda) = n/\lambda$, então o erro padrão é $\text{ep}(\hat{\lambda}) = \sqrt{\hat{\lambda}/n}$.

[6]:
```
lam_hat = y.mean()
se_lam = np.sqrt(lam_hat / n)
ci_lam = (lam_hat - 1.96 * se_lam, lam_hat + 1.96 * se_lam)

pd.Series({"lambda_hat": lam_hat, "ep = sqrt(lambda_hat/n)": se_lam,
           "IC 95% inferior": ci_lam[0], "IC 95% superior": ci_lam[1]}).
↪round(3).to_frame("Modelo de Poisson")
```

[6]:

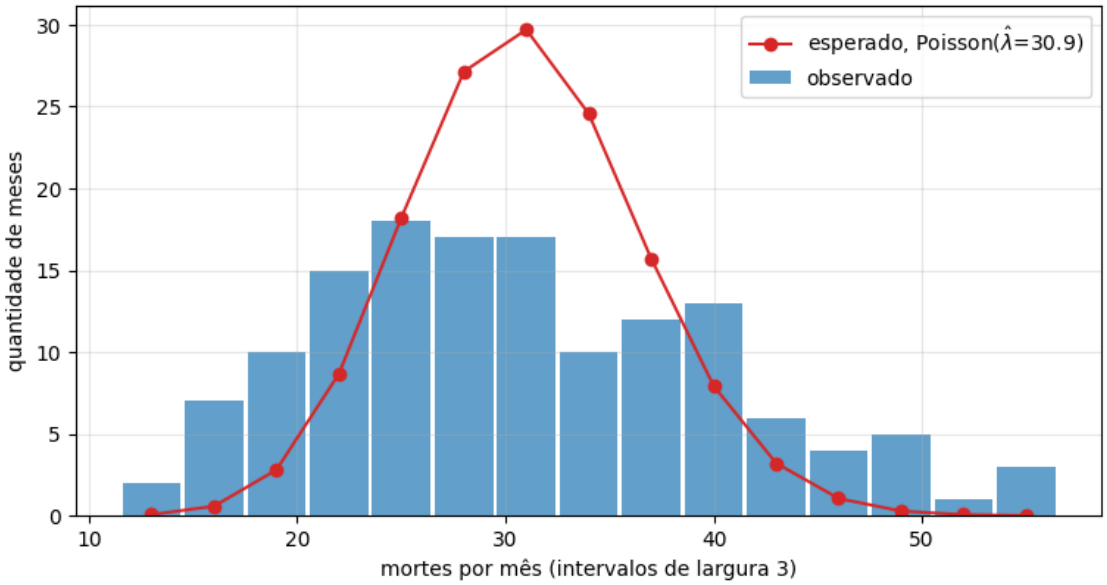
	Modelo de Poisson
lambda_hat	30.914

ep = sqrt(lambda_hat/n)	0.470
IC 95% inferior	29.993
IC 95% superior	31.835

1.3.2 Resposta 3(b)

$\hat{\lambda} = 30{,}91$, ep $= 0{,}47$, IC de 95% (Wald) $[29{,}99,\ 31{,}84]$.

[7]:
```
obs_bin, _ = np.histogram(y, bins=bins)
exp_pois = n * np.diff(poisson.cdf(np.floor(bins), lam_hat))   # meses␣
 ↪esperados por intervalo de largura 3
mids = (bins[:-1] + bins[1:]) / 2
fig, ax = plt.subplots()
ax.bar(mids, obs_bin, width=2.8, color="C0", alpha=0.7, label="observado")
ax.plot(mids, exp_pois, "o-", color="C3", label=rf"esperado,␣
 ↪Poisson($\hat\lambda$={lam_hat:.1f})")
ax.set_xlabel("mortes por mês (intervalos de largura 3)")
ax.set_ylabel("quantidade de meses")
ax.legend()
plt.show()
# +- 1 desvio-padrão
pd.DataFrame({
    "observado": [(y <= 20).mean(), ((y > 20) & (y < 42)).mean(), (y >= 42).
 ↪mean()],
    "Poisson": [poisson.cdf(20, lam_hat), poisson.cdf(41, lam_hat) - poisson.
 ↪cdf(20, lam_hat),
                poisson.sf(41, lam_hat)],
}, index=["P(y <= 20)", "P(21 <= y <= 41)", "P(y >= 42)"]).round(3)
```



[7]:

	observado	Poisson
P(y <= 20)	0.136	0.025
P(21 <= y <= 41)	0.729	0.942
P(y >= 42)	0.136	0.033

1.3.3 Resposta 3(c)

A distribuiçao de Poisson fica concentrada mais no intervalo de um desvio-padrão(+-): $[21, 41]$ tem probabilidade 0,942 contra 0,729 observados na prática, e dá só 0,025 e 0,033 para as caldas, quando o observado é 0,136 em cada ponta.

[8]:
```
ybar, s2 = y.mean(), y.var(ddof=1)
D = np.sum((y - ybar) ** 2) / ybar   # ~ chi2(n-1) sob o modelo de Poisson
pd.Series({"média": ybar, "variância (ddof=1)": s2, "variância/média": s2 /␣
 ↪ybar,
           "estatística de dispersão D": D, "graus de liberdade": n - 1,
           "p-valor P(chi2_139 > D)": chi2.sf(D, n - 1)}).to_frame("teste de␣
 ↪dispersão").map(lambda v: f"{v:.4g}")
```

[8]:

	teste de dispersão
média	30.91
variância (ddof=1)	92.25
variância/média	2.984
estatística de dispersão D	414.8
graus de liberdade	139
p-valor P(chi2_139 > D)	3.087e-29

1.3.4 Resposta 3(d)

Sim, tem uma sobredispersão consideravel: variância/média = 2,98, teste de dispersão $D \approx 3 \times 10^{-29}$. O erro padrão do modelo de Poisson calculado na 3(b) ficou subestimado.

[9]:
```
ll_norm = norm.logpdf(y, mu_hat, np.sqrt(sigma2_hat)).sum()
ll_pois = poisson.logpmf(y, lam_hat).sum()
fit = pd.DataFrame({"k (parâmetros)": [2, 1], "log-verossimilhança máx":␣
 ↪[ll_norm, ll_pois]},
                   index=["Gaussiano", "Poisson"])
fit["AIC"] = -2 * fit["log-verossimilhança máx"] + 2 * fit["k (parâmetros)"]
fit.round(2)
```

[9]:

	k (parâmetros)	log-verossimilhança máx	AIC
Gaussiano	2	-514.87	1033.73
Poisson	1	-571.51	1145.03

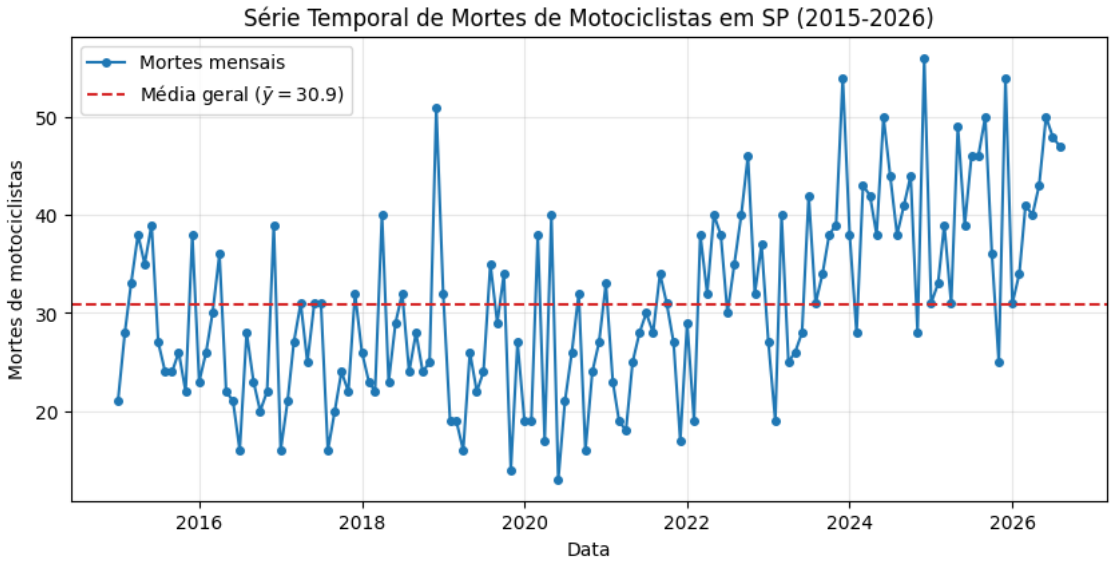
1.3.5 Resposta 3(e)

O modelo Gaussiano ganha: AIC de 1033,7 contra 1145,0 da Poisson.

1.4 Questão 4: Série temporal

[10]:
```
fig, ax = plt.subplots(figsize=(10, 4.5))
ax.plot(dates, y, marker="o", ms=4, color="C0", label="Mortes mensais")
ax.axhline(mu_hat, color="C3", linestyle="--", label=rf"Média geral␣
 ↪($\bar{{y}}={mu_hat:.1f}$)")
ax.set_xlabel("Data")
ax.set_ylabel("Mortes de motociclistas")
ax.set_title("Série Temporal de Mortes de Motociclistas em SP (2015-2026)")
ax.legend()
plt.show()

# Médias anuais para ilustrar a tendência
df_y = pd.DataFrame({"mortes": y}, index=dates)
print("Média de mortes por ano:")
print(df_y.groupby(df_y.index.year).mean().round(2).T.to_string())
```




```
Média de mortes por ano:
         2015  2016   2017   2018   2019   2020   2021   2022   2023   2024
2025   2026
mortes  29.58  25.5  24.67  28.92  24.75  24.33  26.08  34.67  33.58  40.83
39.92  41.75
```

1.4.1 Resposta 4

O gráfico mostra que a hipótese de dados i.i.d não é valida:

1. **Tendência de alta visível:** De 2015 a 2020 a média ficava na casa dos 25 a 27 mortos/mês. De 2021 em diante (pós-pandemia/boom de entregas), a média disparou, passando dos 40 mortos/mês no período recente (2024-2026).
2. **Sazonalidade:** Todo fim de ano (especialmente dezembro) rola um pico isolado de mortes, possivelmente proximo das festas de fim de ano, as pessoas estão se deslocando com mais frequencia, tanto para entrega de aplicativos, como encontros comemorativos.
3. **Autocorrelação:** Um mês alto tende a ser seguido por outro mês alto. Tratar esses dados como observações independentes gera subestimativa das incertezas e ignora a dinâmica do problema.